6. Poročilo: Luščenje modelskih parametrov in razdelčni modeli

Modelska analiza I, 2023/24

Aljaž Ravnikar, 23232128

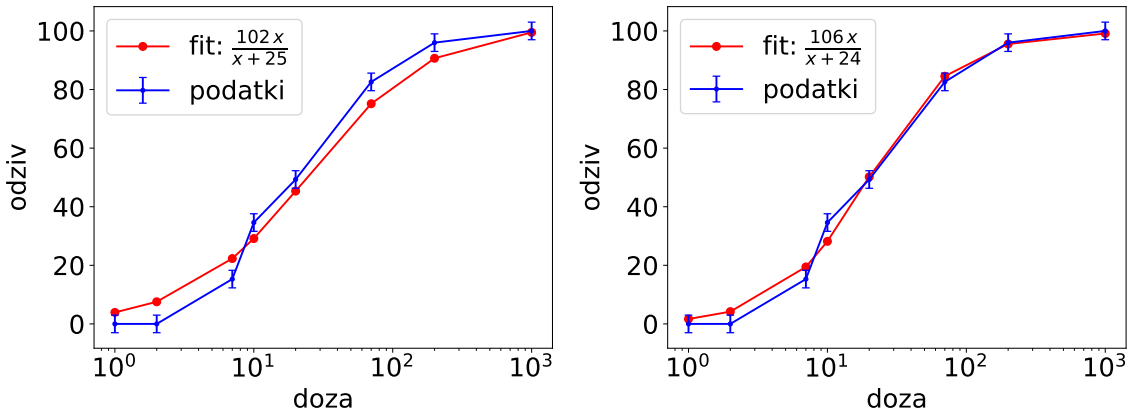
19. november 2023

1 Odziv tkiva na reagente

Rešujemo stacionaren odziv tkiva na reagente po zvezi:

$$y = \frac{y_0\, x}{x + a} \tag{1}$$

Parametra y_0 in a lahko ugotovimo ročno, saj model ni preveč kompleksen, lahko pa uporabimo rutino `curve fit` v scipy in poljubno metodo – delujejo vse, mi pa smo uporabljali *Levenberg-Marquardt-ovo metodo* (LM).



(a) Ročno ugotovljeni parametri c_0 in λ

(b) Z metodo Levenberg-Marquardt

Slika 1: Rešitve za osnoven problem

Sistem lahko linearizirамo:

$$f(x) = \frac{1}{y} = \frac{1}{y_0} + \frac{a}{y_0}\frac{1}{x} = \sum_{j=1}^{M} a_j\, \Phi_j(x) \longrightarrow a_1 = \frac{1}{y_0},\ a_2 = \frac{a}{y_0},\ \Phi_1(x) = 1,\ \Phi_2(x) = \frac{1}{x} \tag{2}$$

Pri tem se transformira tudi napaka:

$$\frac{1}{y \pm \sigma} \approx f(x) \pm \frac{\sigma}{y^2} \longrightarrow \tilde{\sigma} = \frac{\sigma}{y^2} \tag{3}$$

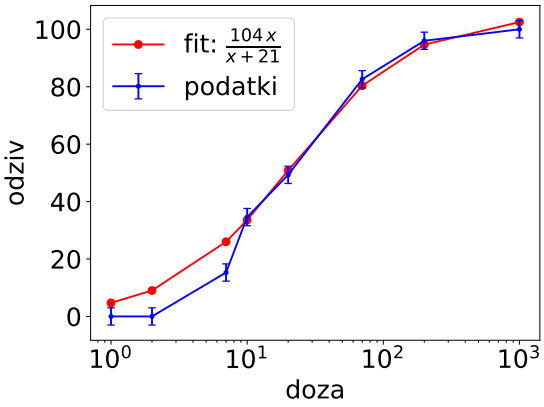
Linearizirani sistem lahko rešimo preprosti z rešitvijo matrične enačbe $A\,\vec{a} = \vec{b}$, kjer je za naš primer število parametrov in dimenzije matrike ter vektorjev enako $M = 2$:

$$A_{11} = \sum_{i=1}^{N} \frac{1}{\tilde{\sigma_i}^2} \qquad b_1 = \sum_{i=1}^{N} \frac{f(x_i)}{\tilde{\sigma_i}^2} \tag{4}$$

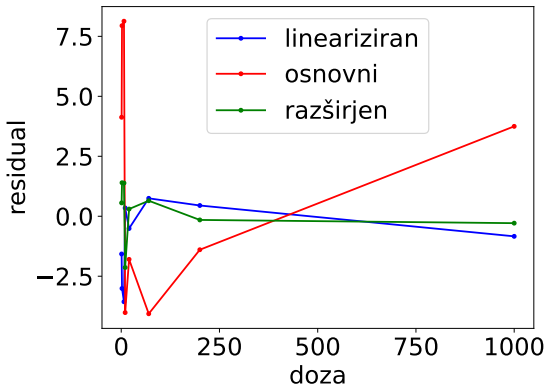
$$A_{12} = A_{21} = \sum_{i=1}^{N} \frac{1}{x_i\,\tilde{\sigma_i}^2} \qquad b_2 = \sum_{i=1}^{N} \frac{f(x_i)}{x_i\,\tilde{\sigma_i}^2}$$

$$A_{22} = \sum_{i=1}^{N} \frac{1}{x_i^2\,\tilde{\sigma_i}^2}$$

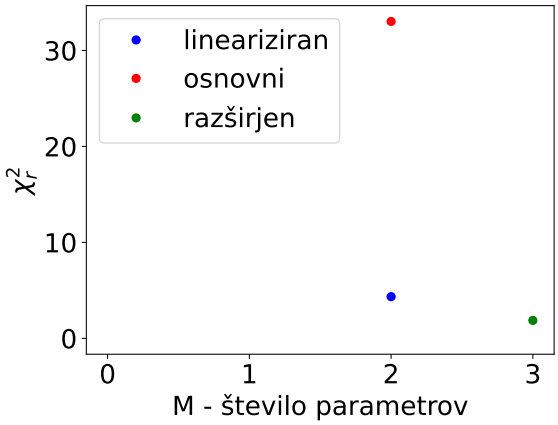
Taka rešitev je predstavljena na spodnji sliki, kjer je za primerjavo pretvorjena nazaj v osnovni (nelinearen) problem. Opazimo, da z linearizacijo celo malo zmanjšamo napako (χ^2), medtem ko jo dodaten parameter p očitno zmanjša še za polovico. Ker znaša tak $\chi^2_r = 0,34$ je to že zelo nizka vrednost in obstaja verjetnost, da smo precenjevali napake.



Slika 2: Rešitev za lineariziran problem



Slika 3: Residuali modelov



Slika 4: Reduciran χ^2_r

2 Čistilnost ledvic

Čistilnost ledvic lahko v osnovi opišemo z enorazdelčnim in dvorazdelčnim modelom in jih primerjamo z izmerjenimi podatki. Poskusimo uporabiti tudi več-razdelčne modele.

$$
\begin{aligned}
c(t) &= A\,e^{-\lambda t} \\
c(t) &= A\,e^{-\lambda_1 t} + B\,e^{-\lambda_2 t} \\
c(t) &= A\,e^{-\lambda_1 t} + B\,e^{-\lambda_2 t} + C\,e^{-\lambda_3 t} \\
c(t) &= A\,e^{-\lambda_1 t} + B\,e^{-\lambda_2 t} + C\,e^{-\lambda_3 t} + D\,e^{-\lambda_4 t} \\
c(t) &= A\,e^{-\lambda_1 t} + B\,e^{-\lambda_2 t} + C\,e^{-\lambda_3 t} + D\,e^{-\lambda_4 t} + E\,e^{-\lambda_5 t}
\end{aligned}
\tag{5}
$$

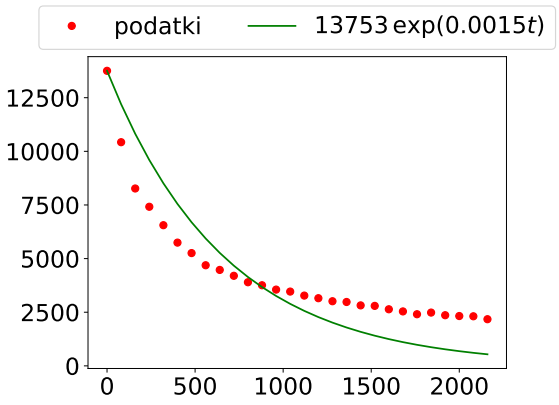
Lahko uporabimo tudi konstanto A_0, ki popisuje sevanje iz ozadja:

$$c(t) = A\,e^{-\lambda t} + A_0 \tag{6}$$

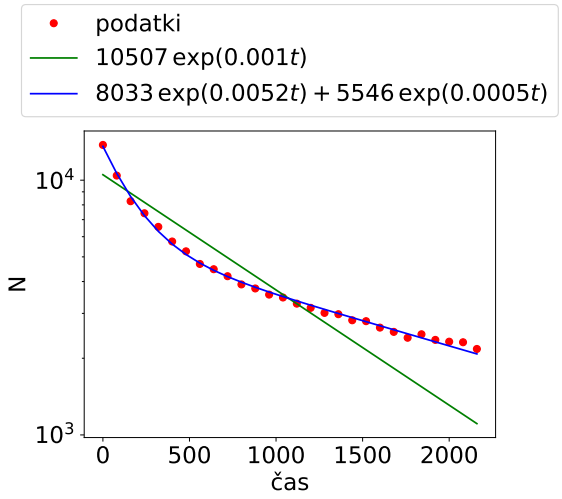
in poljubno osnovo eksponenta:

$$c(t) = A\,osnova^{-\lambda t} + A_0 \tag{7}$$

Ugotovimo, da je za uspešno rešitev potreben ustrezen začetni približek, edinole pri enorazdelčnem modelu z dvema parametroma je še mogoče rešitev dobiti ročno. Ta rešitev predstavlja premico na log y-osi. Z večanjem razdelkov sicer zmanjšujemo napako le do trorazdelčnega modela – več ni smiselno uporabljati. Ker ne poznamo negotovosti meritev, ne moremo izvesti testa χ^2, lahko pa to naredimo brez deljenja s σ in primerjamo le razlike med izračunanimi in izmerjenim vrednostimi ($|y_i - f(x_i)|$), kar smo tudi storili. Skupna napaka modela, dobljena kot absolutna vsota napak izračuna glede na meritev - residualov, ki jih vrne algoritem, z ozadjem sevanja se nahaja med dvo in eno-razdelčno. Zanimivo je, da se z isto napako nahaja tudi model s poljubno osnovo, ki je konvergirala zelo blizu Eulerjevega števila, uporabljenega v drugih modelih. Tako lahko ugotovimo, da upoštevanje sevanja z ozadjem bolje popiše naše izmerke.



(a) Ročno ugotovljeni parametri



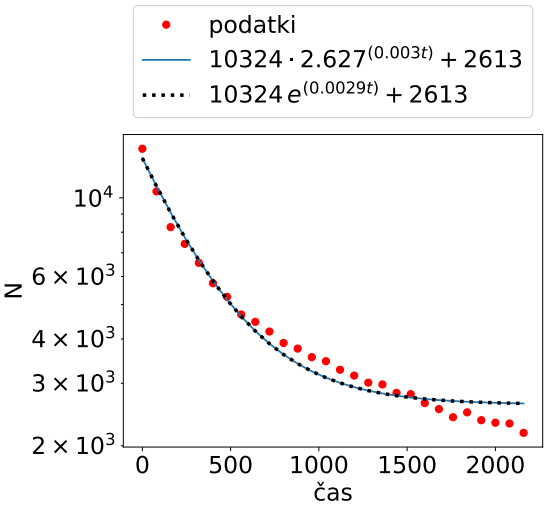
(b) Rešitev enorazdelčnega modela z začetnim približkom $C_0 = N[1] = 13753$ in $\lambda = 0,001$ ter dovrazdelčnega z $C_1 = C_2 = 1$, $\lambda_1 = 0,01$ in $\lambda_2 = 0,1$ z metodo Levenberg-Marquardt

Slika 5: rešitve enorazdelčnega in dvorazdelčnega modela za čiščenje krvi ledvicah

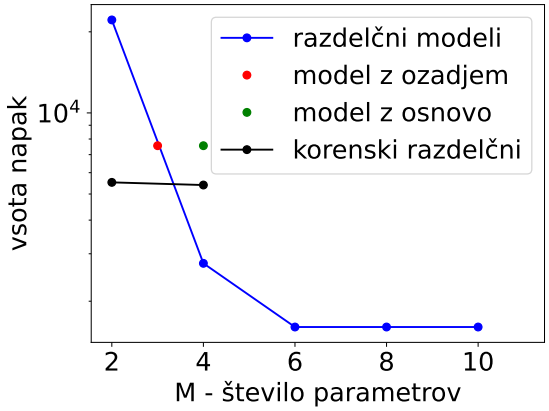
Poleg ozadja smo dodali tudi dva modela s korenskim časom:

$$c(t) = A\, e^{-\lambda \sqrt{t}} \tag{8}$$
$$c(t) = A\, e^{-\lambda_1 \sqrt{t}} + B\, e^{-\lambda_2 \sqrt{t}}$$

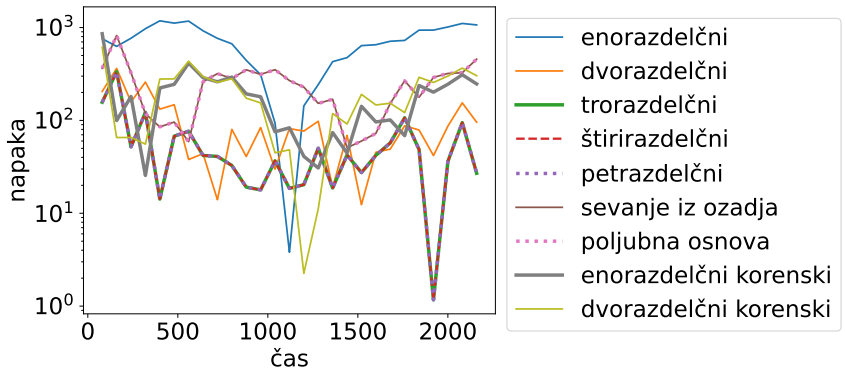
kjer ima enorazdelčni korenski model občutno manjšo absolutno vsoto napak od navadnega enorazdelčnega. Dvorazdelčni korenski model ne prispeva bistveno k natančnejši rešitvi, saj se dogaja enako, kot pri višanju razdelkov navadnih razdelčnih modelov nad tri.



Slika 6: Uporaba poljubne osnove pri sevanju iz ozadja.



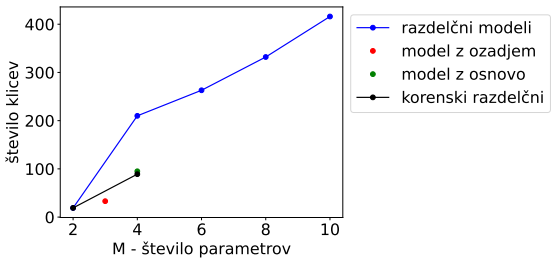
Slika 7: Odvisnost absolutne vsote napak od modelov in števila parametrov



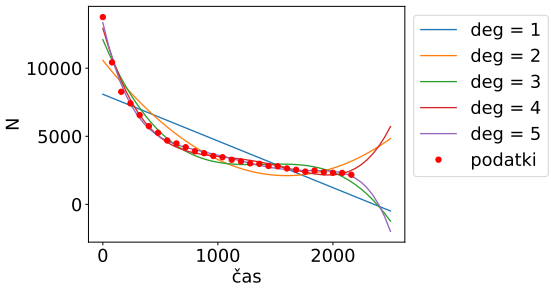
Slika 8: Napaka pri uporabi več razdelkov različnih metod

Poskusili smo tudi "fitati" polinome na dobljene podatke. Pri tem smo uporabili knjižnico `NumPy` in rutini `polyfit` in `poly1d`. Pri tem opazimo, da višanje reda bolj natančno popiše funkcijo, vendar je z tak popis dovolj točen le na območju definiranih podatkov, saj polinom izven njih le bolj "pobezlja". Napaka rešitve se asimptotsko približuje nični, na logaritemski skali pa je začuda viden skok, katerega vzrok nam ni znan.

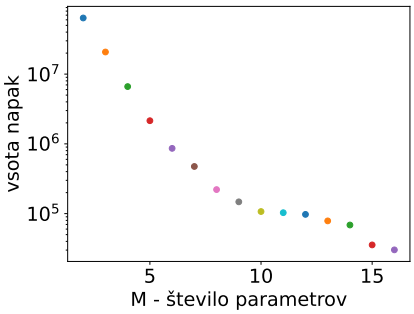
Opazimo, da polinomi ne popisujejo pravilno fizikalnega dogajanja. Napaka tako dobljene rešitve je pri enakem številu parametrov kot pri razdelčnih modelih lahko za nekaj velikostnih razredov višja, vendar so vseeno uporabni, če ne poznamo boljšega funkcijskega popisa.



Slika 9: Odvisnost števila klicev funkcije znotraj LM algoritma



Slika 10: Uporaba polinomskih funkcij



Slika 11: Absolutna vsota napak polinomov do 15. reda

3 Magnetni spektrometer

Lahko uporabimo spodnjo splošno enačbo za popis odvisnosti začetnega kota θ_{tg} od kota θ_{fp} in lege x_{fp} na detektorju:

$$\theta_{tg}(x_{fp}, \theta_{fp}) = \sum_{i=0}^{N} \left[\sum_{j=0}^{M} a_{i,j}\, x_{fp}^{j} \right] \theta_{fp}^{i} \tag{9}$$

kjer je M red polinoma za popis odvisnosti $\theta_{tg}(x_{fp})$ in N za $\theta_{tg}(\theta_{fp})$. Tako dobimo najosnovnejšo enačbo takrat, ko oba polinoma razvijemo do prvega reda:

$$\theta_{tg}(x_{fp}, \theta_{fp}) = (a_{00} + a_{01}\, x_{fp}) + (a_{10} + a_{11}\, x_{fp})\, \theta_{fp} \tag{10}$$

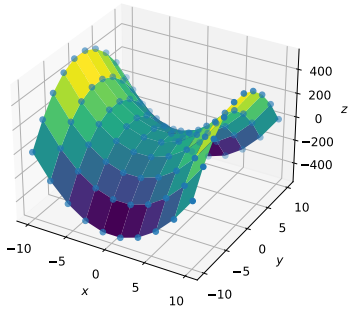
Za reševanje takega sistema uporabljamo singularni razcep (SVD), ki je v Pythonu implementiran v funkciji `numpy.linalg.lstsq`. Da preverimo delovanje algoritma, smo izvedli rekonstrukcijo znane sedlaste funkcije

$$f(x, y) = a_0 + a_1\, x^2 + a_3\, y^2,$$

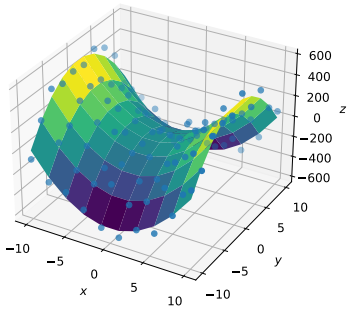
ki smo ji lahko dodatno dodali naključen šum med (-1, 1), pomnožen s stopnjo zašumljenosti.

Opazili smo, da χ^2 eksponentno narašča z večanjem šuma, drugače pa algoritem lepo prilagodi funkcijo podatkom. V primeru brez šuma dobimo zalo majhno vrednost χ_r^2 reda 10^{-27}.

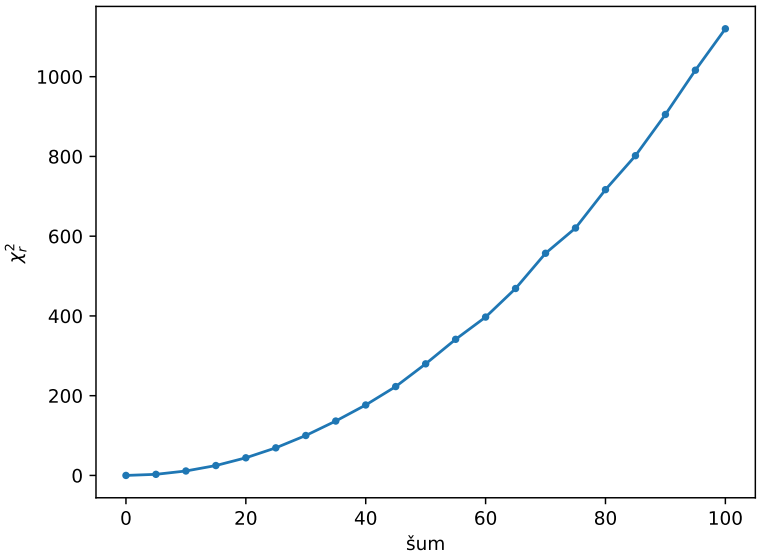
Sedaj lahko analiziramo podatke iz datoteke. Ugotovimo, da se presenetljivo višanje redov polinomov za popis ne odraža v bolj točni rešitvi, temveč ravno obratno; polinomi višjih redov PODIVJAJO.



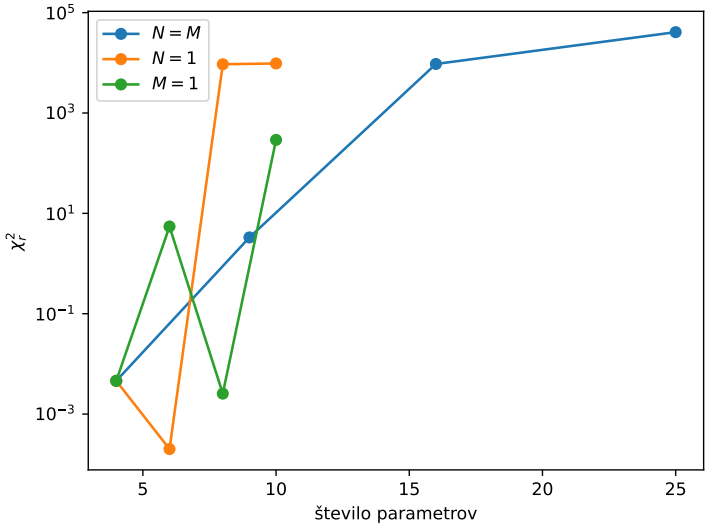
(a) Testna funkcija brez šuma



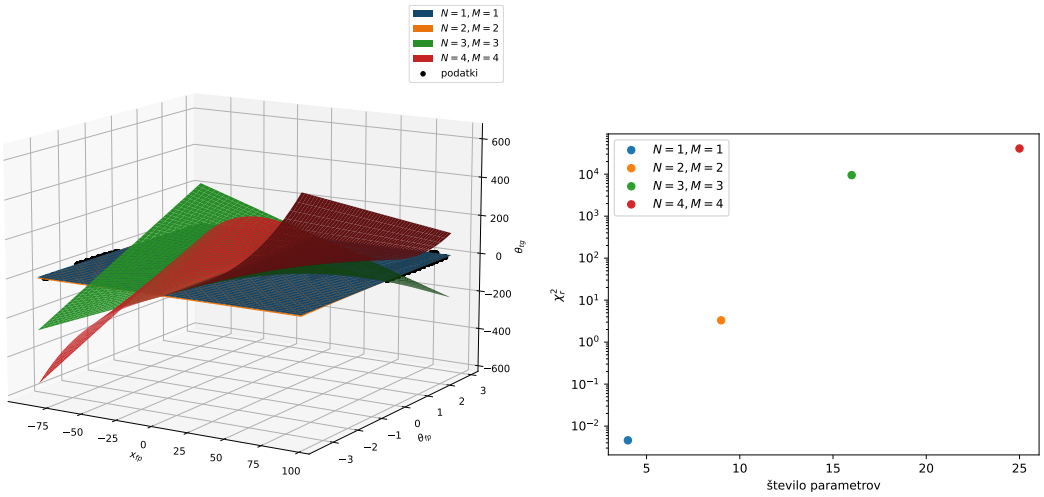
(b) Testna funkcija s šumom



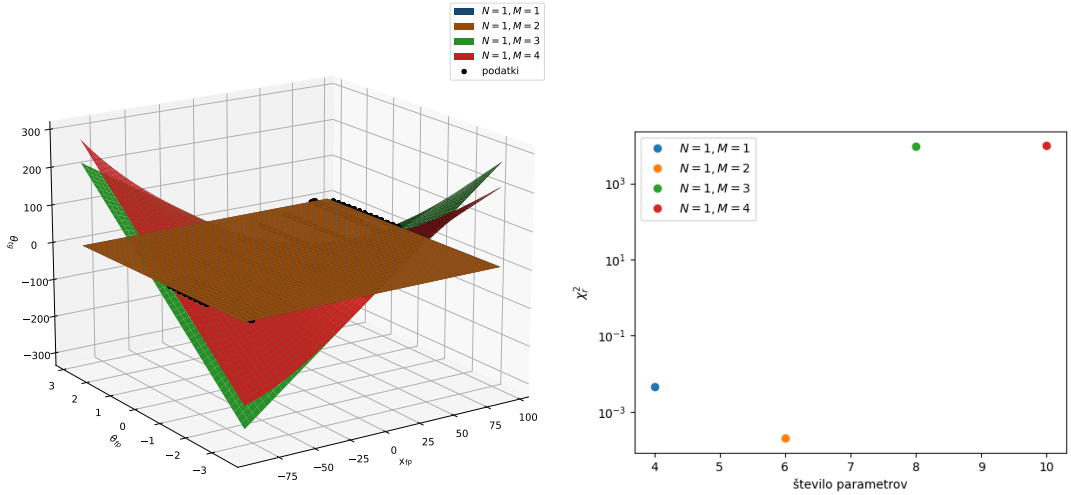
Slika 13: Odvisnost reduciranega χ_r^2 od stopnje zašumljenosti



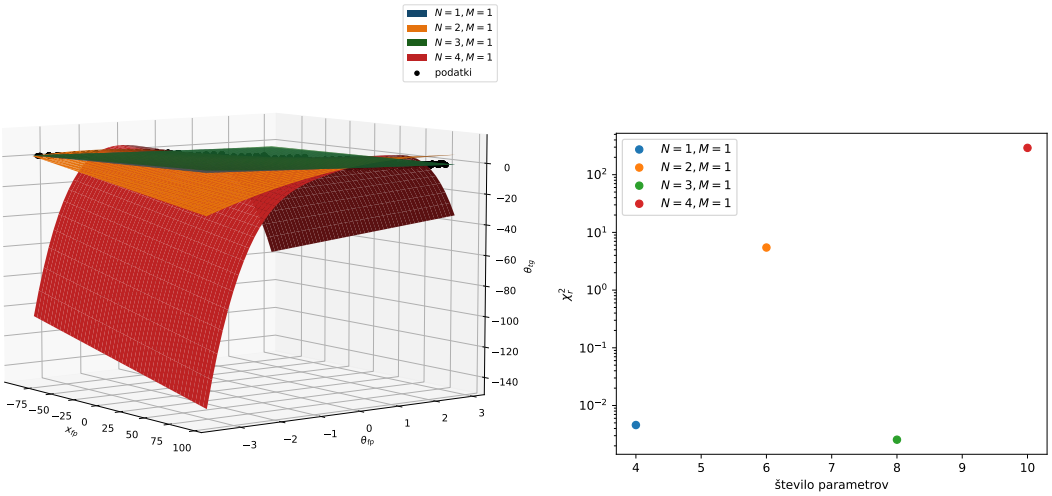
Slika 14: χ_r^2 za vse primere polinomov do 4. reda za N in M



Slika 15: Polinomi z enakimi redi $M = N$



Slika 16: Polinomi z različnimi redi M pri fiksnem $N = 1$



Slika 17: Polinomi z različnimi redi N pri fiksnem $M = 1$

Vidimo, da v primeru ko $N = 1$ in $M = 2$ dobimo najbolj podatkom prilegajoč se popis, ko je $\chi^2_r = 2,0\,10^{-4}$, ki ga opisuje spodnja enačba. Sledi drugi najboljši popis $N = 3$ in $M = 1$, ko $\chi^2_r = 2,6\,10^{-3}$ in tretji (in hkrati najenostavnejši) popis z ravnino $N = M = 1$, kjer je $\chi^2_r = 4,6\,10^{-3}$.

$$\theta_{tg}(x_{fp}, \theta_{fp}) = (a_{00} + a_{01}\,x_{fp} + a_{02}\,x^2_{fp}) + (a_{10} + a_{11}\,x_{fp} + a_{12}\,x^2_{fp})\,\theta_{fp} \tag{11}$$

a	vrednost	singularna vrednost
a_{00}	$1{,}66\,10^{-2}$	982 830
a_{01}	$1{,}71\,10^{-2}$	542 352
a_{02}	$-3{,}19\,10^{-5}$	5 945
a_{10}	-0,854	3 624
a_{11}	$-8{,}63\,10^{-6}$	66
a_{12}	$1{,}25\,10^{-6}$	61

Tabela 1: Vrednost in pomembnost parametrov izbranega modela

Iz zgornjih podatkov lahko sklepamo, da so najmanj pomembni zadnji parametri, zato jih lahko postopoma odstranjujemo in spremljamo model. Iz tega dobimo model, okleščen za zadnja dva parametra, torej je odvisnost od θ_{fp} linearna.

enačba modela	χ^2_r	relativna napaka
$(a_{00} + a_{01}\,x_{fp} + a_{02}\,x^2_{fp}) + (a_{10} + a_{11}\,x_{fp} + a_{12}\,x^2_{fp})\,\theta_{fp}$	$2{,}0086\,10^{-4}$	0 %
$(a_{00} + a_{01}\,x_{fp} + a_{02}\,x^2_{fp}) + (a_{10} + a_{11}\,x_{fp})\,\theta_{fp}$	$2{,}1748\,10^{-4}$	8,27 %
$(a_{00} + a_{01}\,x_{fp} + a_{02}\,x^2_{fp}) + a_{10}\,\theta_{fp}$	$2{,}1793\,10^{-4}$	8,50 %
$(a_{00} + a_{01}\,x_{fp} + a_{02}\,x^2_{fp})$	0,5510	274 243 %

Tabela 2: Zmanjševanje parametrov vpliva na napako

Iz podatkov lahko sklepamo, da je še ustrezen model brez zadnjih dveh parametrov, ki pa je vseeno varčnejši od osnovnega. Ta ima sicer okleščene polinome reda $N = 1$ in $M = 2$ ter skupno 4 parametre.